

PDM 的优化

Teng Zhang

2021 年 1 月 6 日

目前的优化问题为

$$\min_{\mathbf{w}} \frac{1}{2m} \sum_{i \in [m]} \max \left\{ 0, 1 - \frac{y_i \mathbf{w}^\top \mathbf{x}_i}{\bar{\gamma}} \right\}^2, \quad \text{s.t. } \bar{\gamma} > 0, \|\mathbf{w}\|_2 = 1$$

这个形式是有问题的，两个约束都是多余的。注意间隔均值 $\bar{\gamma} = \mathbf{w}^\top \overline{y\mathbf{x}}$ 关于 \mathbf{w} 也是线性的，所以那个比值项是齐次的，放缩 \mathbf{w} 不影响目标函数值。若求得的 \mathbf{w} 使得 $\bar{\gamma} < 0$ ，则 $-\mathbf{w}$ 可使得 $\bar{\gamma} > 0$ 且不改变目标函数值、不破坏第二个约束。同理第二个约束也是多余的，若求得的 \mathbf{w} 范数不为 1，可以将其缩放使范数为 1 且不改变目标函数值。

1 重新优化

将两个约束都去掉，问题变成

$$\min_{\mathbf{w}} \frac{1}{2m} \sum_{i \in [m]} \max \left\{ 0, 1 - \frac{y_i \mathbf{w}^\top \mathbf{x}_i}{\bar{\gamma}} \right\}^2$$

由于放缩 \mathbf{w} 不影响目标函数值，不妨放缩使 $\bar{\gamma} = 1$ ，于是问题可进一步写成

$$\min_{\mathbf{w}} \frac{1}{2m} \sum_{i \in [m]} \max \{0, 1 - y_i \mathbf{w}^\top \mathbf{x}_i\}^2, \quad \text{s.t. } \sum_{i \in [m]} y_i \mathbf{w}^\top \mathbf{x}_i = m$$

这个形式直觉上也是合理的，最优情况是所有样本间隔均为 1，都等于间隔均值，这样损失为零；若有样本间隔 > 1 ，由于间隔的和为 m ，必然存在另一个样本间隔 < 1 ，这样就会产生损失。

记 $\epsilon_i = \max\{0, 1 - y_i \mathbf{w}^\top \mathbf{x}_i\}$ ，则问题可写成

$$\min_{\mathbf{w}, \epsilon_i} \frac{1}{2m} \sum_{i \in [m]} \epsilon_i^2, \quad \text{s.t. } \epsilon_i \geq 0, \epsilon_i \geq 1 - y_i \mathbf{w}^\top \mathbf{x}_i, \sum_{i \in [m]} y_i \mathbf{w}^\top \mathbf{x}_i = m$$

其中约束 $\epsilon_i \geq 0$ 是多余的，因为若求得的 $\epsilon_i < 0$ ，令其为零不破坏约束 $\epsilon_i \geq 1 - y_i \mathbf{w}^\top \mathbf{x}_i$ 且可以使目标函数值变小，因此不存在这种情况。最终的问题为

$$\min_{\mathbf{w}, \epsilon_i} \frac{1}{2m} \sum_{i \in [m]} \epsilon_i^2, \quad \text{s.t. } \epsilon_i \geq 1 - y_i \mathbf{w}^\top \mathbf{x}_i, \sum_{i \in [m]} y_i \mathbf{w}^\top \mathbf{x}_i = m \quad (1)$$

目标函数是二次的，约束都是线性的，因此这是一个凸二次规划，直接调用成熟的 QP 优化包即可。

记 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m] \in \mathbb{R}^{d \times m}$, $\mathbf{Y} = \text{diag}\{y_1, y_2, \dots, y_m\}$, $\boldsymbol{\epsilon} = [\epsilon_1; \epsilon_2; \dots; \epsilon_m]$, 式 (1) 的矩阵形式为

$$\min_{\mathbf{w}, \boldsymbol{\epsilon}} \frac{1}{2m} \boldsymbol{\epsilon}^\top \boldsymbol{\epsilon}, \quad \text{s.t. } \boldsymbol{\epsilon} \geq \mathbf{e} - \mathbf{YX}^\top \mathbf{w}, \quad \mathbf{e}^\top \mathbf{YX}^\top \mathbf{w} = m$$

记 $\mathbf{u} = [\mathbf{w}; \boldsymbol{\epsilon}] \in \mathbb{R}^{d+m}$, 写成 QP 的标准形式是

$$\min_{\mathbf{u}} \frac{1}{2} \mathbf{u}^\top \begin{bmatrix} \mathbf{0} \\ \frac{\mathbf{I}}{m} \end{bmatrix} \mathbf{u}, \quad \text{s.t. } [-\mathbf{YX}^\top, -\mathbf{I}] \mathbf{u} \leq -\mathbf{e}, \quad [\mathbf{XYe}; \mathbf{0}]^\top \mathbf{u} = m$$

这样就可以直接调包了。

2 核化

设 $\kappa(\mathbf{x}, \mathbf{z}) = \phi(\mathbf{x})^\top \phi(\mathbf{z})$, 记 $\mathbf{X} = [\phi(\mathbf{x}_1), \phi(\mathbf{x}_2), \dots, \phi(\mathbf{x}_m)]$, \mathbf{w} 的正交分解为

$$\mathbf{w} = \underbrace{a_1 \phi(\mathbf{x}_1) + a_2 \phi(\mathbf{x}_2) + \dots + a_m \phi(\mathbf{x}_m)}_{\phi_{\mathbf{x}}} + \phi_{\mathbf{x}}^\perp = \phi_{\mathbf{x}} + \phi_{\mathbf{x}}^\perp$$

其中 $\phi_{\mathbf{x}}^\perp \in \ker(\mathbf{X}^\top)$ 。注意 \mathbf{w} 在原问题中只以 $\mathbf{X}^\top \mathbf{w}$ 的形式出现，又

$$\mathbf{X}^\top \mathbf{w} = \mathbf{X}^\top (\phi_{\mathbf{x}} + \phi_{\mathbf{x}}^\perp) = \mathbf{X}^\top \phi_{\mathbf{x}}$$

故原问题最优的 \mathbf{w} 不是唯一的， $\phi_{\mathbf{x}}^\perp$ 可以取 $\ker(\mathbf{X}^\top)$ 中的任意向量。传统的核方法目标函数中还有 \mathbf{w} 的二次正则，所以最小化

$$\|\mathbf{w}\|_2^2 = \|\phi_{\mathbf{x}}\|^2 + \|\phi_{\mathbf{x}}^\perp\|^2 \geq \|\phi_{\mathbf{x}}\|^2$$

必然导致 $\phi_{\mathbf{x}}^\perp = \mathbf{0}$ ，从而有

$$\mathbf{w} = a_1 \phi(\mathbf{x}_1) + a_2 \phi(\mathbf{x}_2) + \dots + a_m \phi(\mathbf{x}_m) = \mathbf{Xa}$$

这就是所谓的表示定理。

对于 PDM，没有二次正则，我们就直接取 $\phi_{\mathbf{x}}^\perp = \mathbf{0}$ 好了，即 $\mathbf{w} = \mathbf{Xa}$ (注意 $\tilde{\mathbf{w}} = \mathbf{w} + \ker(\mathbf{X}^\top)$ 其实都是原问题的最优解)，代入原问题有

$$\min_{\mathbf{a}, \boldsymbol{\epsilon}} \frac{1}{2m} \boldsymbol{\epsilon}^\top \boldsymbol{\epsilon}, \quad \text{s.t. } \boldsymbol{\epsilon} \geq \mathbf{e} - \mathbf{YX}^\top \mathbf{Xa}, \quad \mathbf{e}^\top \mathbf{YX}^\top \mathbf{Xa} = m$$

记 $\mathbf{K} = \mathbf{X}^\top \mathbf{X}$ 为核矩阵， $\mathbf{v} = [\mathbf{a}; \boldsymbol{\epsilon}] \in \mathbb{R}^{2m}$, 写成 QP 的标准形式是

$$\min_{\mathbf{v}} \frac{1}{2} \mathbf{v}^\top \begin{bmatrix} \mathbf{0} \\ \frac{\mathbf{I}}{m} \end{bmatrix} \mathbf{v}, \quad \text{s.t. } [-\mathbf{YK}, -\mathbf{I}] \mathbf{v} \leq -\mathbf{e}, \quad [\mathbf{KYe}; \mathbf{0}]^\top \mathbf{v} = m$$

解出 \mathbf{v} 后，对于未知样本 \mathbf{z} , 预测为

$$\begin{aligned} \mathbf{w}^\top \phi(\mathbf{z}) &= (a_1 \phi(\mathbf{x}_1) + a_2 \phi(\mathbf{x}_2) + \dots + a_m \phi(\mathbf{x}_m))^\top \phi(\mathbf{z}) \\ &= a_1 \kappa(\mathbf{x}_1, \mathbf{z}) + a_2 \kappa(\mathbf{x}_2, \mathbf{z}) + \dots + a_m \kappa(\mathbf{x}_m, \mathbf{z}) \end{aligned}$$

3 实验

如果是用 matlab 做实验，图省事可以直接调用 `quadprog` 函数，这是 matlab 优化工具箱自带的，但 matlab 的版本最好不要晚于 2018，越新越好，最好是 2020b，早期版本的 matlab 的优化工具箱很坑。如果没有新版本的 matlab，可以用 `cvx` 工具箱 (<http://cvxr.com/cvx/>)，这是凸优化那本书的作者 Stephen P. Boyd 他们搞的，可以无缝嵌入到 matlab 代码里，很好用。

如果是用 python 做实验，可以用 `cvxopt` 包 (<https://cvxopt.org/userguide/coneprog.html#quadratic-programming>)，或者 `cvxpy` 包 (https://www.cvxpy.org/examples/basic/quadratic_program.html)，后者是 matlab 下的 `cvx` 工具箱的 python 移植版。